PACIENTE VIRTUAL ADAPTATIVO

Reporte 1 de métricas del sistema

Línea base local, sin modelo de lenguaje

Tarea principal: TA-024 · Medición de rendimiento, carga y calidad del frontend

Tarea relacionada: TA-023 · Benchmark del recuperador de evidencia (RAG)

Fecha de ejecución: 10 de noviembre de 2026, 14:37 a 15:03 (hora de Lima)

Entorno: Servidor local (http://localhost:3000) sin archivo .env

Carpeta de evidencia: pruebas/38_ta024_metricas/reporte_local/

Estado: Reporte 1 de 2. El reporte 2 repetirá las mediciones con Groq, Supabase/pgvector y voz

Contenido

1. Objetivo y alcance 3
2. Correspondencia con las tareas del backlog 3
3. Entorno de ejecución 3
4. Metodología y comandos 4
4.1 Preparación (una sola vez) 4
4.2 Levantar el servidor 4
4.3 Variables de la terminal de mediciones 4
4.4 Latencia por turno (TA-024) 4
4.5 Throughput y carga concurrente (TA-024) 5
4.6 Latencia de la voz (TA-024) 5
4.7 Recuperación de evidencia, RAG (TA-023) 5
4.8 Frontend: Lighthouse y axe-core (TA-024) 5
4.9 Gráficos y tablas 6
5. Resultados 6
5.1 Latencia por turno 6
5.2 Throughput y carga concurrente 8
5.3 Recuperación de evidencia (RAG, TA-023) 9
5.4 Rendimiento del frontend (Lighthouse) 10
5.5 Accesibilidad automática (axe-core, WCAG 2.1 AA) 11
5.6 Mediciones no ejecutadas en este reporte 12
6. Conclusiones de la línea base 12
7. Limitaciones 13
8. Siguiente paso: reporte 2 13
Anexo A. Capturas de la ejecución 14
Anexo B. Archivos generados 17

Si el índice aparece vacío, haga clic derecho sobre él en Word y elija «Actualizar campos».

1. Objetivo y alcance

Este reporte documenta la primera ejecución de la batería de métricas del sistema. Cubre las métricas que el informe técnico tenía marcadas como **[PENDIENTE]**: latencia por turno (p50, p90, p95 y p99), throughput bajo carga concurrente, métricas de recuperación de evidencia (RAG), rendimiento del frontend (Lighthouse) y accesibilidad automática (axe-core, WCAG 2.1 AA).

La corrida se hizo con el servidor **sin archivo `.env`**. Por eso el backend funcionó en su modo de desarrollo local:

- **Modelo de lenguaje:** `llm_mode = local-development`. Los agentes responden con el texto de la evidencia, sin llamar a Groq.
- **Recuperación:** `deterministic-case-fallback`. Es el recuperador local del caso, no Supabase/pgvector.
- **Sesiones:** en memoria (`session_store = memoria`), no en Supabase.
- **Voz neuronal:** apagada (falta `TTS_PROVIDER=edge`).

Por lo tanto, este reporte es la **línea base sin LLM**: mide cuánto tarda el propio sistema en atender un turno (enrutador determinista, política de revelado, recuperación, guardia de salida y persistencia). En el reporte 2, la diferencia entre la latencia con Groq y esta línea base indicará cuánto aporta el modelo. Las mediciones del frontend (Lighthouse y axe) no dependen del modelo, así que valen como resultado final.

2. Correspondencia con las tareas del backlog

Tabla 1. *Pruebas, herramientas y tarea a la que corresponden*

Prueba	Herramienta / script	Tarea	Estado en este reporte
Latencia por turno	01_latencia_turnos.py	TA-024	Ejecutada (línea base)
Throughput y carga concurrente	02_carga_concurrente.py	TA-024	Ejecutada (línea base)
Latencia de la voz neuronal	03_latencia_voz.py	TA-024	No ejecutada: voz apagada
Recuperación de evidencia (P@k, Recall@k, Hit@k, RAGAS por IDs)	python -m evals (arnés existente)	TA-023	Ejecutada con el recuperador local
Rendimiento del frontend (Lighthouse)	04_frontend_lighthouse_axe.mjs	TA-024	Ejecutada (resultado final)
Accesibilidad WCAG 2.1 AA (axe-core)	04_frontend_lighthouse_axe.mjs	TA-024	Ejecutada (resultado final)
Usabilidad percibida (SUS)	05_sus.py + cuestionario	TA-024	Pendiente: requiere encuestas
Gráficos y tablas	graficar.py	TA-024	Ejecutado: 11 gráficos

Todos los scripts están en `pruebas/38_ta024_metricas/codigo/`. Los datos crudos (CSV y JSON) están en `reporte_local/resultados/` y los gráficos en `reporte_local/graficos/`.

3. Entorno de ejecución

Tabla 2. *Equipo y configuración de la corrida*

Elemento	Valor
Sistema operativo	Windows 10 Pro 10.0.19045
Procesador	Intel64 Family 6 Model 165 (12 núcleos lógicos)
Python / Node.js	Python 3.13.7 · Node.js 22.19.0

Elemento	Valor
Servidor	FastAPI 0.141.1 sobre Uvicorn 0.54.0, un proceso, puerto 3000
Cliente de pruebas	Mismo equipo que el servidor (localhost): la red no influye
LLM / recuperación / sesiones	local-development / deterministic-case-fallback / memoria
Navegador de Lighthouse y axe	Chromium de Playwright 1.63.0, sin interfaz gráfica (headless)
Conjunto de evaluación	backend/evals/datasets/clinical_v1.json: 100 preguntas, 10 casos, 5 especialidades, 10 escenarios

Cada script guarda estos datos en el campo `entorno_cliente` de su JSON de resultados, para poder repetir la medición en las mismas condiciones.

4. Metodología y comandos

4.1 Preparación (una sola vez)

Instala las dependencias de Python con los extras de evaluación, voz y pruebas, Lighthouse y axe-core sin modificar `package.json`, y el navegador Chromium de Playwright:

```
npm install
npm run setup -- --extras evals,voz,dev
npm install --no-save lighthouse axe-core
npx playwright install chromium
```

4.2 Levantar el servidor

En una terminal aparte, desde la raíz del proyecto. `npm start` compila el CSS y las imágenes y levanta Uvicorn en el puerto 3000:

```
npm start
```

4.3 Variables de la terminal de mediciones

Todos los comandos se ejecutan desde la raíz del proyecto. `$PY` y `$M` son rutas absolutas:

```
$PY = "$PWD\backend\.venv\Scripts\python.exe"
$M  = "$PWD\pruebas\38_ta024_metricas\codigo"
$env:PYTHONIOENCODING = "utf-8"
```

4.4 Latencia por turno (TA-024)

Qué hace: recorre los 10 casos del conjunto de evaluación. Por cada caso abre una consulta de invitado (`POST /api/ai/sessions`) y envía sus 10 preguntas en orden (`POST /api/ai/sessions/{id}/message`), con la credencial de capacidad en `X-Session-Token`, como lo haría un alumno.

Cómo mide: cronometra en el cliente (`time.perf_counter`) cada petición completa, de punta a punta: enrutador, política de revelado, recuperación, agente, guardia y guardado. Registra el código HTTP, el agente que respondió y el tipo de pregunta. Los percentiles se calculan con interpolación lineal. Con `--repeticiones 2` se enviaron 200 turnos.

```
& $PY $M\01_latencia_turnos.py --repeticiones 2
```

4.5 Throughput y carga concurrente (TA-024)

Qué hace: simula 1, 2, 4 y 8 alumnos conversando a la vez (asyncio + httpx). Cada alumno abre su propia consulta y envía 5 turnos. Entre un nivel y el siguiente espera 20 s.

Cómo mide: el throughput es el número de turnos respondidos con 200 dividido por la duración de la ronda. La latencia se reporta con p50 y p95 por nivel. La tasa de error lleva su intervalo de confianza del 95 % de Wilson, adecuado para proporciones con muestras pequeñas.

```
& $PY $M\02_carga_concurrente.py
```

4.6 Latencia de la voz (TA-024)

Qué hace: pide 8 frases de paciente y doctor a `GET /api/voz` (edge-tts) y mide el tiempo hasta el primer trozo de audio (lo que el alumno espera antes de oír al personaje) y hasta el audio completo. En esta corrida el script se detuvo: «La voz neuronal está apagada», porque no hay `TTS_PROVIDER=edge` sin `.env`.

```
& $PY $M\03_latencia_voz.py
```

4.7 Recuperación de evidencia, RAG (TA-023)

Qué hace: usa el arnés existente `backend/evals`. Por cada una de las 100 preguntas enruta la consulta, aplica la política de revelado, recupera las k evidencias y compara sus IDs con los esperados. También comprueba que no aparezcan evidencias de otro caso, ni no autorizadas, ni texto protegido (fallos de seguridad).

Métricas:

- **Precisión@k:** evidencias correctas entre las k devueltas, con k como denominador.
- **Recall@k:** evidencias esperadas que se encontraron.
- **Hit@k:** si se encontró al menos una evidencia esperada.
- **Abstención:** en preguntas sin respuesta (dato ausente, protegido u otro caso), si el sistema no devolvió nada.
- **RAGAS por IDs:** context precision y context recall de RAGAS 0.4.3.

```
cd backend
.\.venv\Scripts\python.exe -m evals --k 3 5 --ragas ids --output
..\pruebas\38_ta024_metricas\resultados\rag\configurado
cd ..
```

El aviso `fatal: not a git repository` que aparece al inicio no es un error. El arnés intenta registrar el commit medido, pero esta copia del proyecto no tiene carpeta `.git`; guarda `git_commit: null` y continúa.

4.8 Frontend: Lighthouse y axe-core (TA-024)

Qué hace: audita 5 páginas (portada, simulación, docente, grupos y privacidad) en móvil y escritorio:

- **Lighthouse:** puntajes de rendimiento, accesibilidad, buenas prácticas y SEO, más FCP, LCP, TBT y CLS. En móvil simula red y CPU lentas.
- **axe-core:** se inyecta en Chromium (Playwright) y evalúa las reglas WCAG 2.0 y 2.1 de niveles A y AA, en viewports de 390 × 844 y 1440 × 900.

```
node $M\04_frontend_lighthouse_axe.mjs
```

4.9 Gráficos y tablas

Lee todo lo que haya en `resultados/` y genera los PNG de `graficos/` y el archivo `resultados/resumen_metricas.md`, con todas las tablas de este reporte:

```
& $PY $M\graficar.py
```

5. Resultados

5.1 Latencia por turno

Se enviaron 200 turnos y los **200 respondieron con HTTP 200**, sin errores. El primer turno no mostró arranque en frío: los valores con y sin él coinciden.

Tabla 3. *Latencia por turno, línea base sin LLM*

Medición (ms)	n	Media	DE	p50	p90	p95	p99	Máx.
Inicio de consulta	20	13	3	13	16	17	19	19
Turno (todos)	**200**	**45**	**10**	**44**	**59**	**62**	**66**	**69**
Turno · Médico asistente	100	41	9	39	53	58	65	66
Turno · Paciente	80	48	10	46	61	62	66	69
Turno · Laboratorio	14	52	6	54	60	61	61	61
Turno · Radiología	6	39	5	37	45	46	46	46

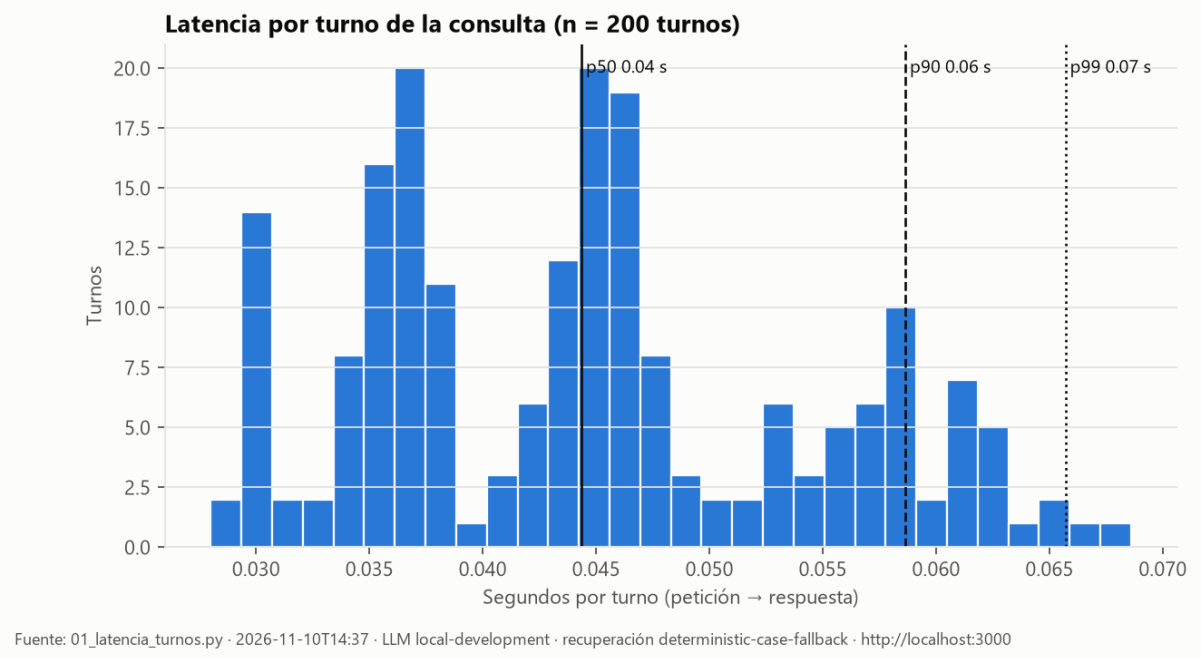


Figura 1. *Distribución de la latencia por turno con p50, p90 y p99 (n = 200)*

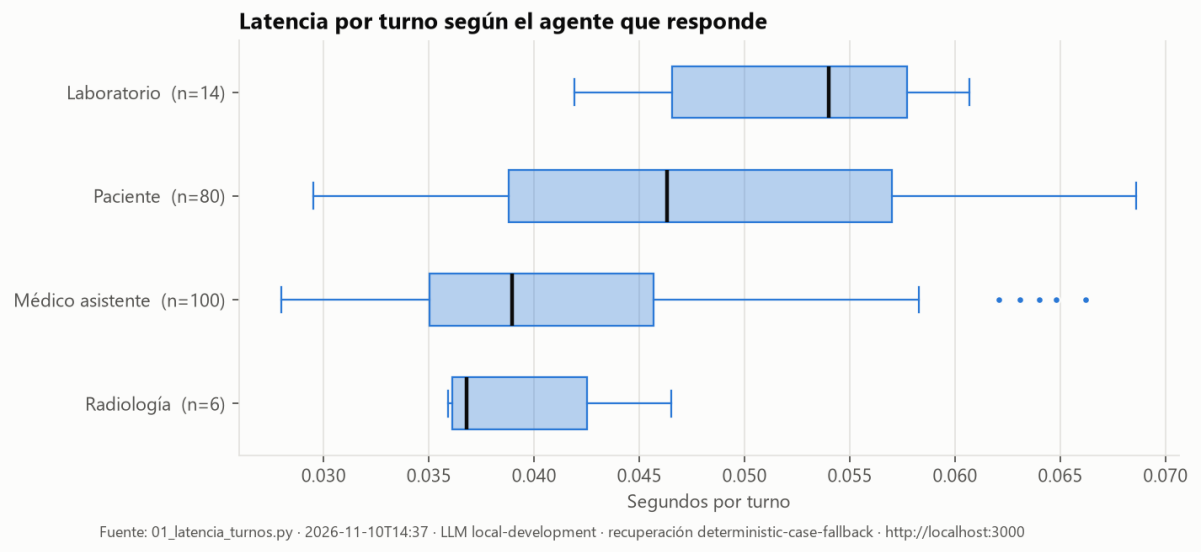


Figura 2. *Latencia por turno según el agente que responde*

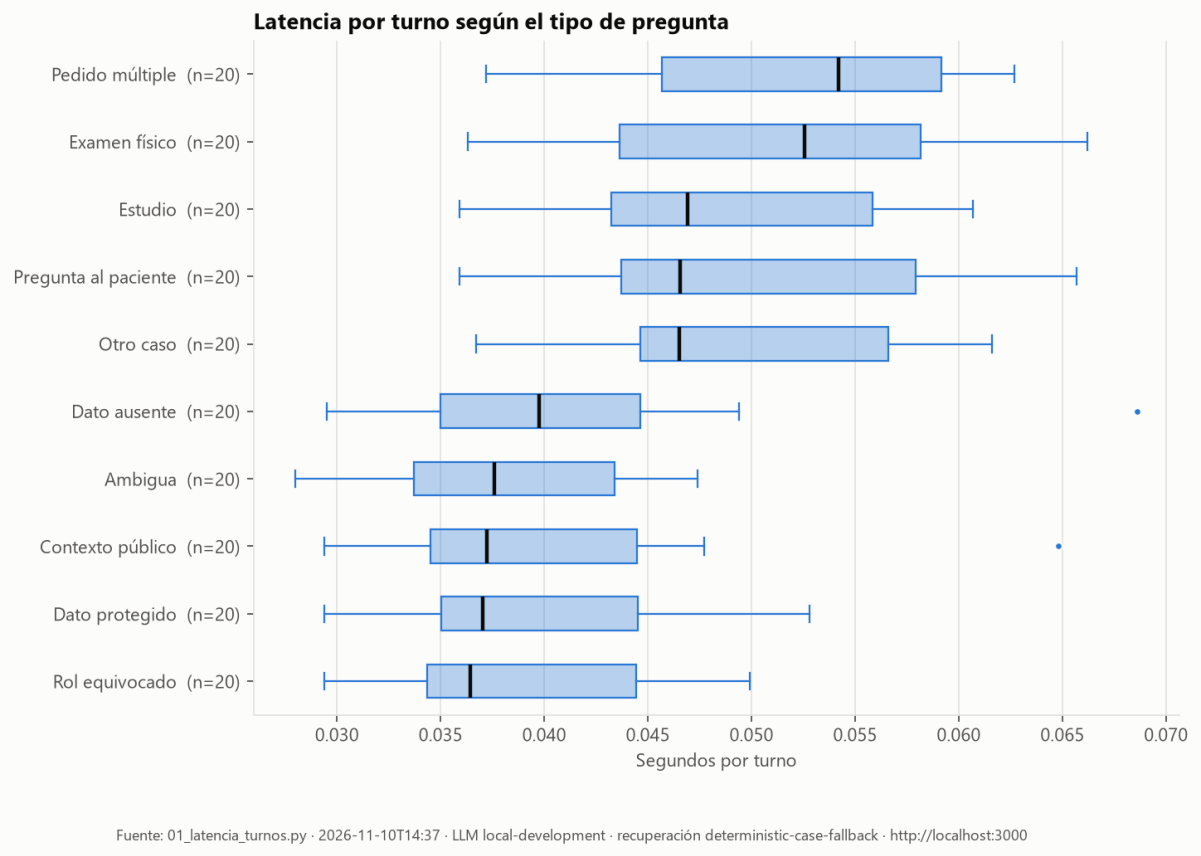


Figura 3. *Latencia por turno según el tipo de pregunta*

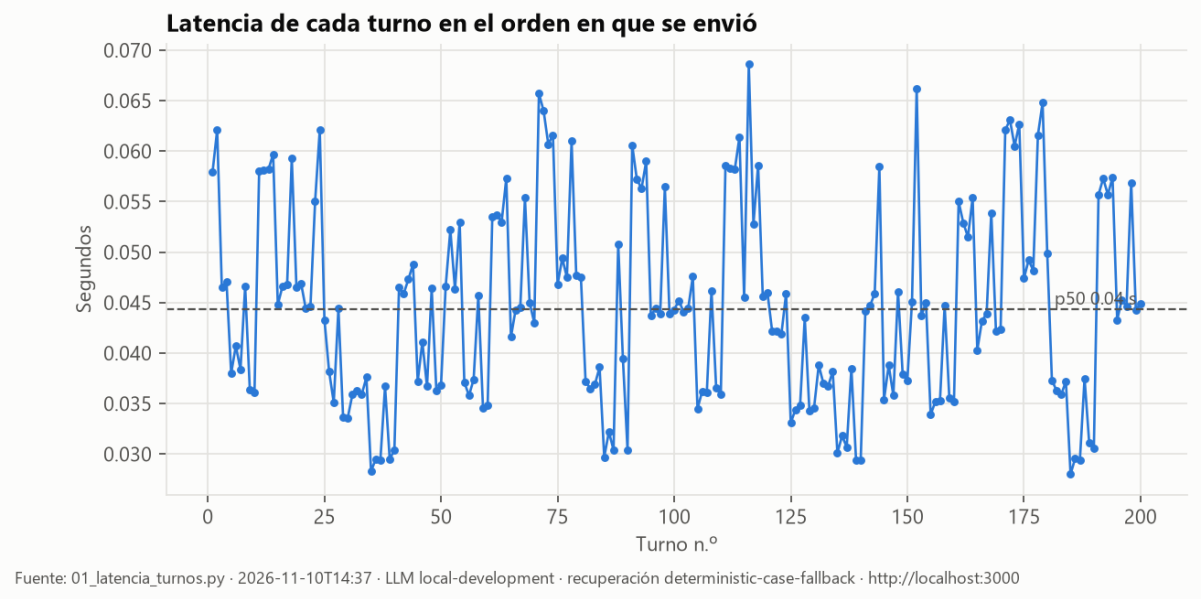


Figura 4. *Latencia de cada turno en orden de envío: sin degradación a lo largo de la corrida*

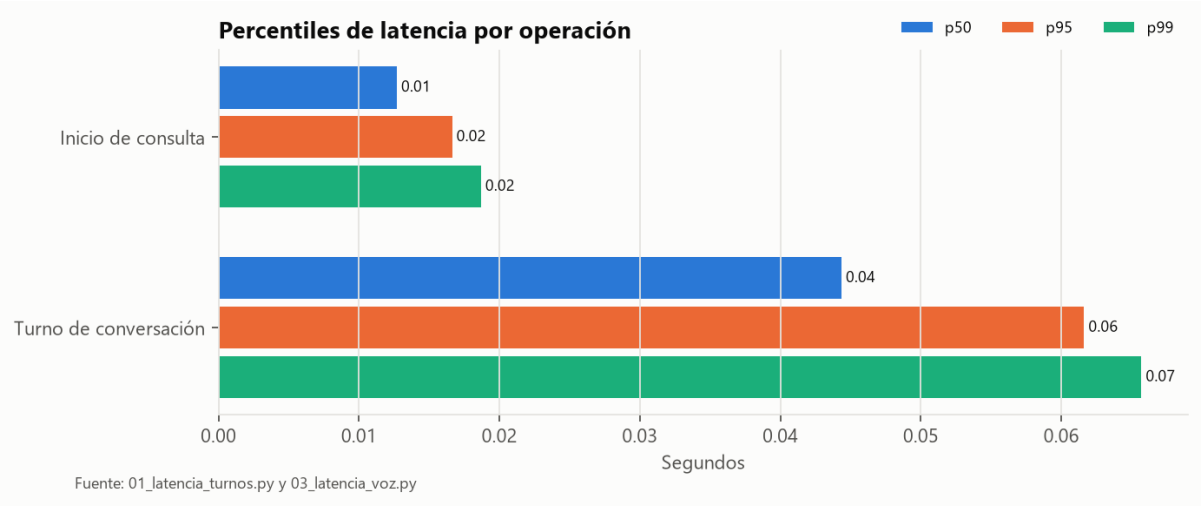


Figura 5. *Percentiles p50, p95 y p99 del inicio de consulta y del turno*

5.2 Throughput y carga concurrente

Tabla 4. *Throughput y latencia según el número de alumnos simultáneos*

Alumnos simultáneos	Turnos OK / enviados	Duración (s)	Turnos/min	p50 (ms)	p95 (ms)	Error % [IC 95 %]
1	5/5	0,52	579	44	45	0 [0–43,4]
2	10/10	0,79	757	102	110	0 [0–27,8]
4	20/20	1,17	1 030	174	205	0 [0–16,1]
8	40/40	2,18	1 099	359	445	0 [0–8,8]

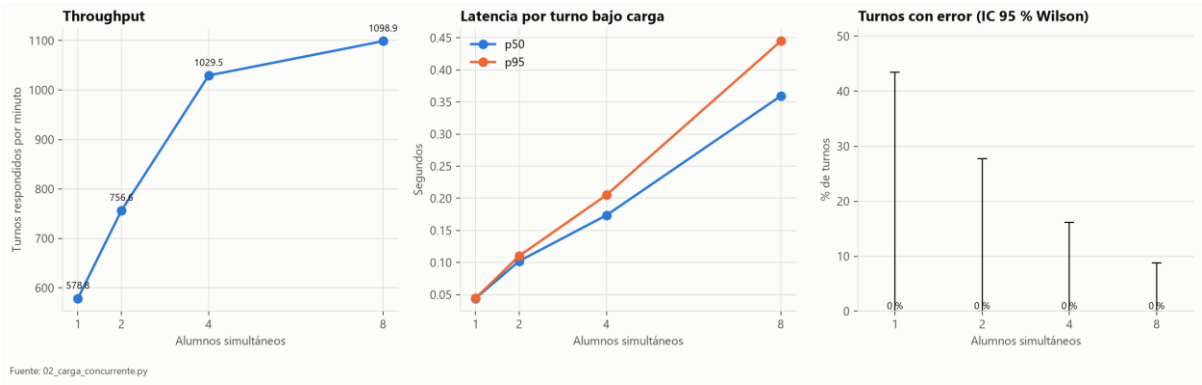


Figura 6. *Throughput, latencia bajo carga y porcentaje de turnos con error (IC 95 % de Wilson)*

Ningún nivel tuvo errores. El throughput sube de 579 a 1 030 turnos por minuto entre 1 y 4 alumnos, y con 8 se estabiliza en unos 1 100. Desde ahí la latencia crece casi en proporción al número de alumnos: el p50 pasa de 44 ms con 1 alumno a 359 ms con 8. Indica que **el servidor atiende los turnos prácticamente en serie** en un solo proceso de Uvicorn: las peticiones simultáneas esperan su turno en lugar de procesarse en paralelo. Con Groq, la espera de red al modelo dominará, así que el reporte 2 mostrará si el gateway aprovecha esa espera.

5.3 Recuperación de evidencia (RAG, TA-023)

Se evaluaron 100 consultas de 10 casos (20 por especialidad), con k = 3 y k = 5. El estado de la corrida es ok y hubo **0 fallos de seguridad**: ninguna evidencia de otro caso, ninguna no autorizada y ningún texto protegido.

Tabla 5. *Métricas de recuperación (recuperador local; en RAGAS por IDs: context precision 1,000 y context recall igual a Recall@k)*

Especialidad	k	P@k	Recall@k	Hit@k	Abstención	Fallos seg.
Global	3	0,460	0,950	1,000	1,000	0
Global	5	0,312	0,978	1,000	1,000	0
Cirugía general	3	0,467	0,938	1,000	1,000	0
Emergencias	3	0,367	1,000	1,000	1,000	0
Ginecología y obstetricia	3	0,500	0,975	1,000	1,000	0
Medicina interna	3	0,500	0,897	1,000	1,000	0
Pediatría	3	0,467	0,938	1,000	1,000	0

El Hit@3 global es 1,000 (n = 50 consultas con referencia; IC 95 % de Wilson 0,929–1,000). La precisión baja es esperable por cómo se define la métrica: cada pregunta tiene 1 o 2 evidencias esperadas y el denominador es k, así que con k = 3 el máximo posible ronda 0,33–0,67. Por eso se interpreta junto con Recall@k y Hit@k. La abstención de 1,000 significa que en las preguntas sin respuesta válida el recuperador no devolvió ninguna evidencia.

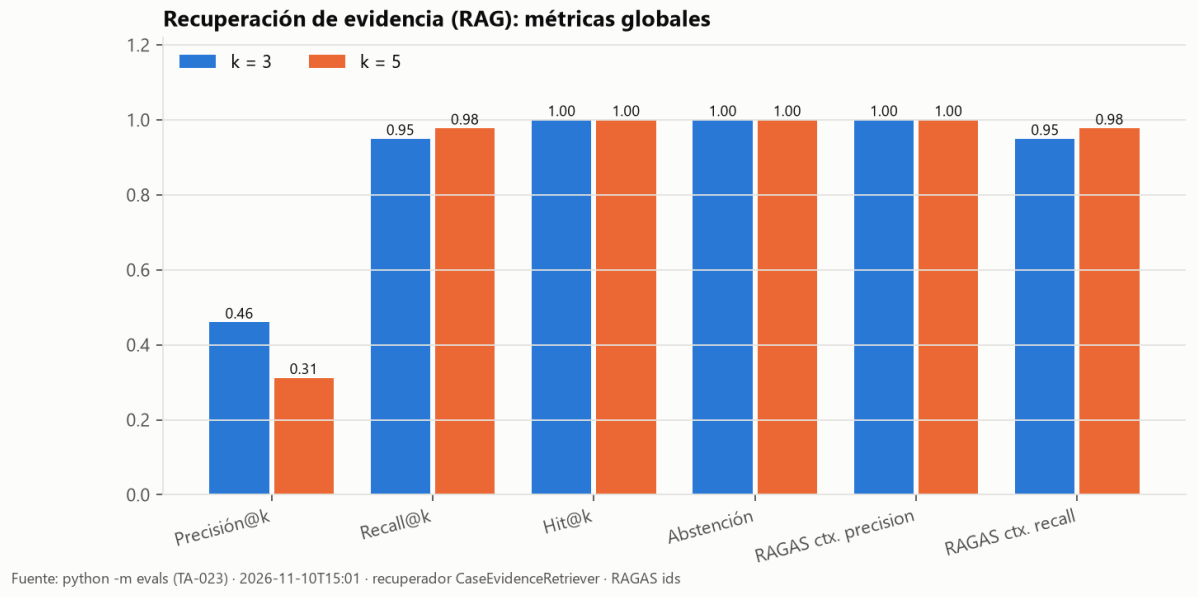


Figura 7. *Métricas globales de recuperación para k = 3 y k = 5*

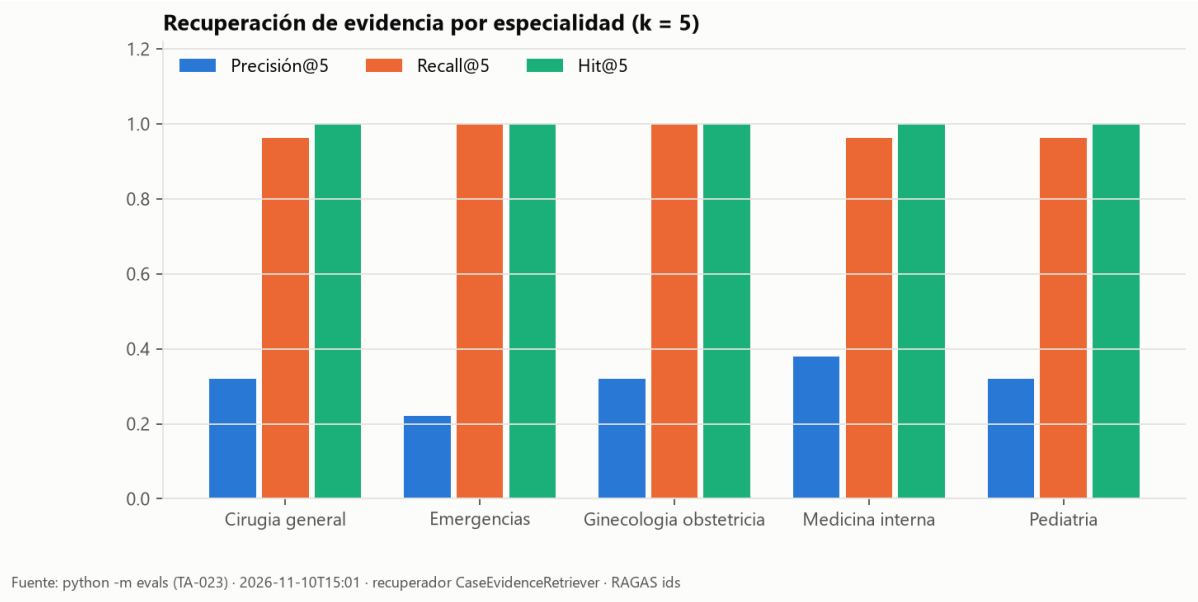


Figura 8. *Precisión, Recall y Hit por especialidad (k = 5)*

5.4 Rendimiento del frontend (Lighthouse)

Tabla 6. *Puntajes Lighthouse (0–100) y métricas de carga; TBT = 0 ms en todas las páginas*

Página	Modo	Rend.	Acces.	B. prác.	SEO	LCP (ms)	CLS	Peso (KB)
Portada	Móvil	**74**	96	100	100	**8 966**	0	1 474
Portada	Escritorio	92	96	100	100	1 712	0,002	1 498
Simulación	Móvil	**74**	100	100	100	**9 188**	0	1 536
Simulación	Escritorio	92	100	100	100	1 761	0,003	1 553
Docente	Móvil	97	100	100	54	1 640	0	346
Docente	Escritorio	100	100	100	54	543	0	346
Grupos	Móvil	100	100	100	54	1 212	0	270
Grupos	Escritorio	99	100	100	54	293	0,001	270

Página	Modo	Rend.	Acces.	B. prác.	SEO	LCP (ms)	CLS	Peso (KB)
Privacidad	Móvil	100	100	100	100	1 487	0	29
Privacidad	Escritorio	100	100	100	100	516	0	29

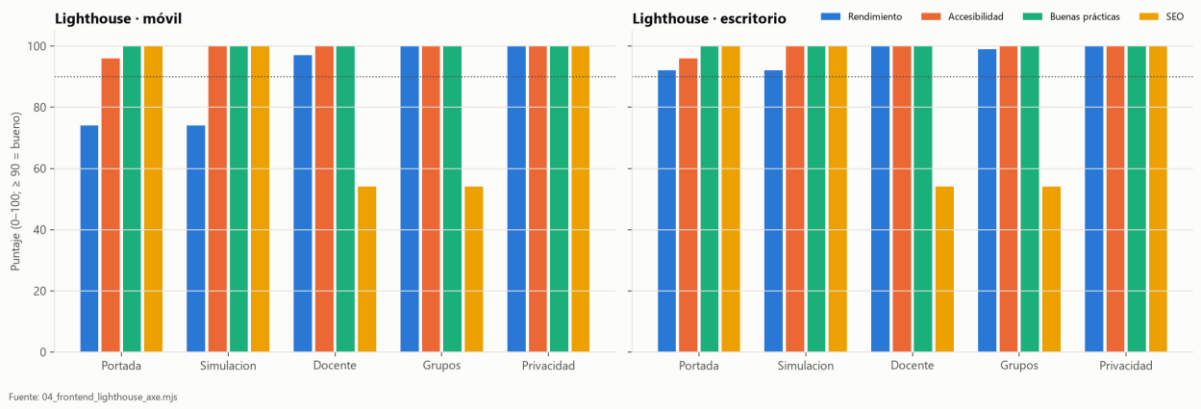


Figura 9. *Puntajes Lighthouse por página en móvil y escritorio (línea punteada: 90 = bueno)*

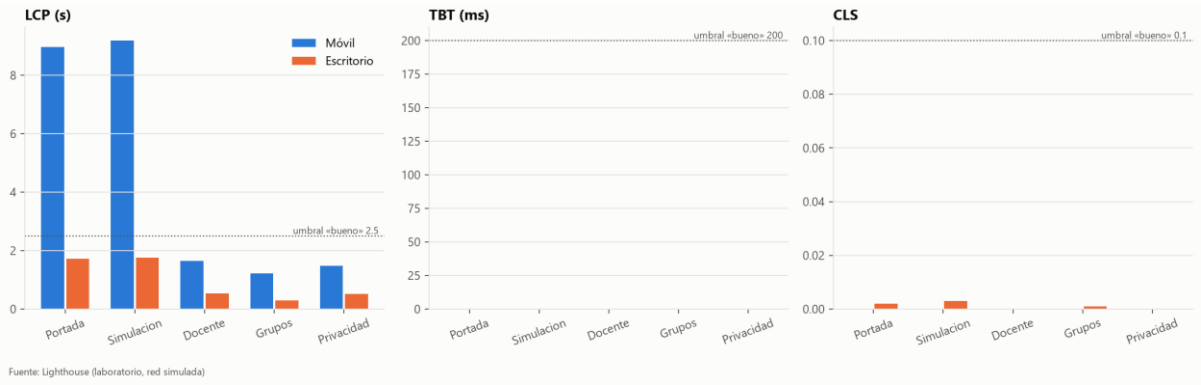


Figura 10. *LCP, TBT y CLS frente a los umbrales de «bueno» de Core Web Vitals*

En escritorio, las cinco páginas superan 90 en rendimiento y tienen CLS prácticamente nulo (sin saltos de diseño) y TBT = 0 (sin bloqueo del hilo principal).

En móvil, la portada y la simulación bajan a 74 por el LCP de unos 9 s: la red lenta simulada tarda en cargar su contenido principal, de alrededor de 1,5 MB, frente a menos de 350 KB en las demás páginas. Es la mejora de rendimiento más clara: comprimir o diferir las imágenes y el avatar de esas dos páginas.

El SEO de 54 en docente y grupos es **intencional**: esas páginas llevan `noindex, nofollow` porque son áreas privadas que no deben aparecer en buscadores.

5.5 Accesibilidad automática (axe-core, WCAG 2.1 AA)

De 10 combinaciones de página y dispositivo, 7 no tienen ningún incumplimiento. Hay 3 hallazgos, los 3 de impacto «grave» y ninguno «crítico»:

Tabla 7. *Incumplimientos WCAG detectados por axe-core*

Página	Regla	Criterio WCAG	Elemento	Corrección sugerida
Portada (móvil y escritorio)	color-contrast	1.4.3 Contraste mínimo (AA)	.text-white/85	Subir la opacidad del texto a 100 % u oscurecer el fondo hasta un contraste ≥ 4,5:1

Página	Regla	Criterio WCAG	Elemento	Corrección sugerida
Docente (escritorio)	label-content-name-mismatch	2.5.3 Etiqueta en el nombre (A)	#toggle-panel-theme	Que el aria-label del botón incluya el texto visible

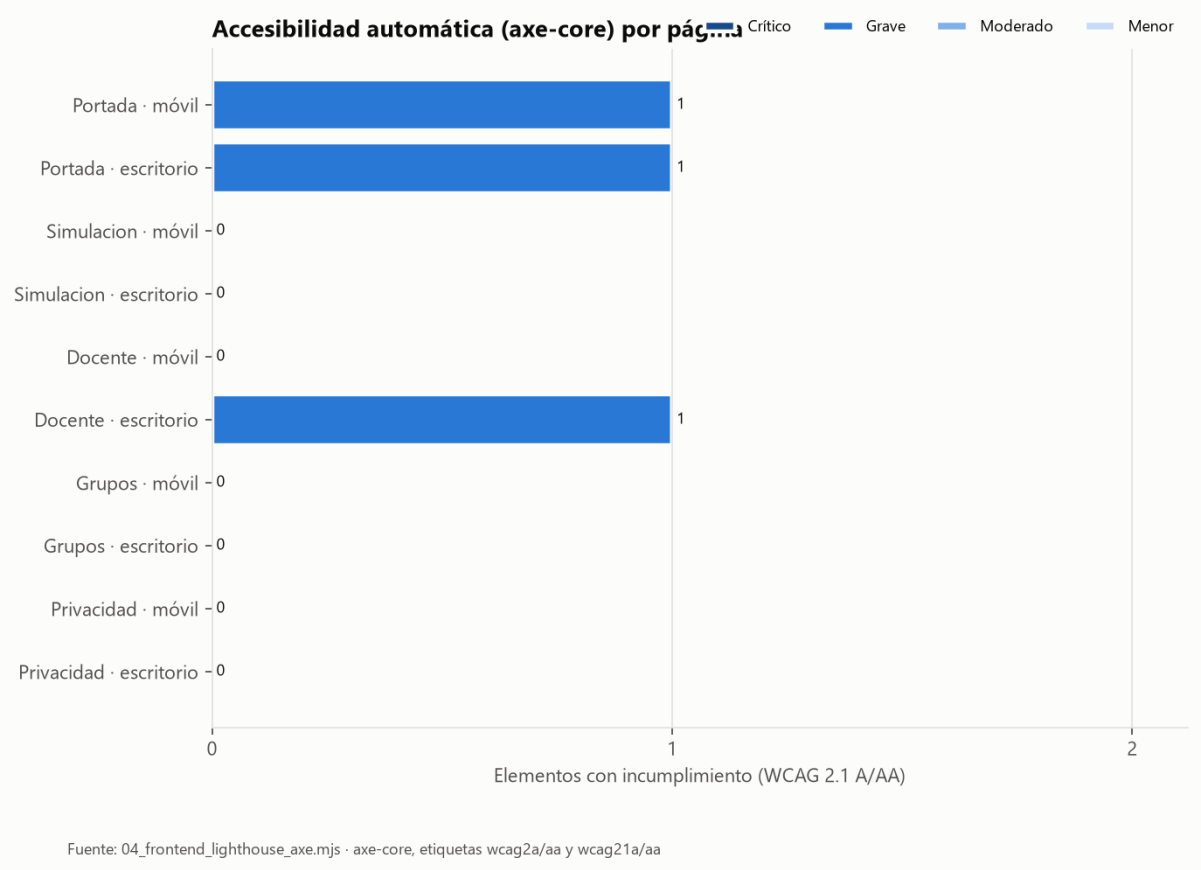


Figura 11. *Elementos con incumplimiento WCAG por página e impacto*

axe-core detecta automáticamente alrededor de un tercio de los problemas WCAG. Este resultado no reemplaza una revisión manual con lector de pantalla y teclado.

5.6 Mediciones no ejecutadas en este reporte

- **Voz neuronal:** quedó pendiente para el reporte 2, cuando el `.env` incluya `TTS_PROVIDER=edge`.
- **SUS:** requiere el piloto con usuarios. El cuestionario en español está en `datos/cuestionario_sus.md` y las respuestas se anotan en `datos/sus_respuestas.csv`.
- **RAGAS con juez LLM (faithfulness y answer relevancy):** requiere Groq; se ejecutará con `--ragas llm --generate-responses`.

6. Conclusiones de la línea base

1. **El costo propio del sistema es bajo:** p50 de 44 ms y p99 de 66 ms por turno, sin errores en 200 turnos. Cualquier latencia adicional en el reporte 2 corresponderá principalmente al modelo y a los servicios externos (Groq, Supabase).
2. **Bajo carga, el servidor procesa en serie:** el throughput se estabiliza en unos 1 100 turnos/min con 8 alumnos simultáneos y la latencia crece de forma lineal. No hubo errores en ningún nivel. Para el despliegue conviene comprobar en el reporte 2 cómo se comporta con la espera de red del LLM y, si hace falta, usar más workers.

3. **La recuperación es segura y completa:** Hit@k = 1,000, Recall@5 = 0,978 y 0 fallos de seguridad en 100 consultas. Falta repetirla con el recuperador configurado (Supabase/pgvector).
4. **Frontend:** el escritorio está por encima de 90 en todas las páginas. Las mejoras concretas son el LCP móvil de la portada y la simulación, y 2 ajustes de accesibilidad (contraste y nombre accesible de un botón).

7. Limitaciones

- **Cliente y servidor en el mismo equipo:** la latencia no incluye la red de internet ni el arranque en frío de Vercel.
- **Sin LLM real:** las respuestas son el texto de la evidencia. No se midió el tiempo del modelo, el consumo de tokens ni los límites de Groq (429).
- **Recuperador local de respaldo:** los resultados de RAG no representan todavía al recuperador semántico desplegado.
- **Muestras de carga pequeñas** (5 turnos por alumno): los intervalos de confianza de la tasa de error son anchos con 1 y 2 alumnos.
- **Lighthouse se ejecutó una vez:** conviene repetirlo 3 veces y reportar la mediana.

8. Siguiente paso: reporte 2

Copiar a la raíz el `.env` del proyecto, con `GROQ_API_KEYS`, las claves de Supabase y `TTS_PROVIDER=edge`, y reiniciar `npm start`. Al iniciar, el script 01 debe mostrar `llm_mode=groq-pool`. Después, repetir las mediciones dependientes del modelo:

```
Remove-Item -Recurse pruebas\38_ta024_metricas\resultados\rag\configurado
& $PY $M\01_latencia_turnos.py --repeticiones 2
& $PY $M\02_carga_concurrente.py
& $PY $M\03_latencia_voz.py
cd backend
.\.venv\Scripts\python.exe -m evals --k 3 5 --ragas ids --output
..\pruebas\38_ta024_metricas\resultados\rag\configurado
cd ..
& $PY $M\graficar.py
```

Los resultados de este reporte 1 quedan guardados en `reporte_local/` y no se sobrescriben.

Anexo A. Capturas de la ejecución



Figura 12. *Preparación del entorno: dependencias de Python, Lighthouse, axe-core y Chromium*

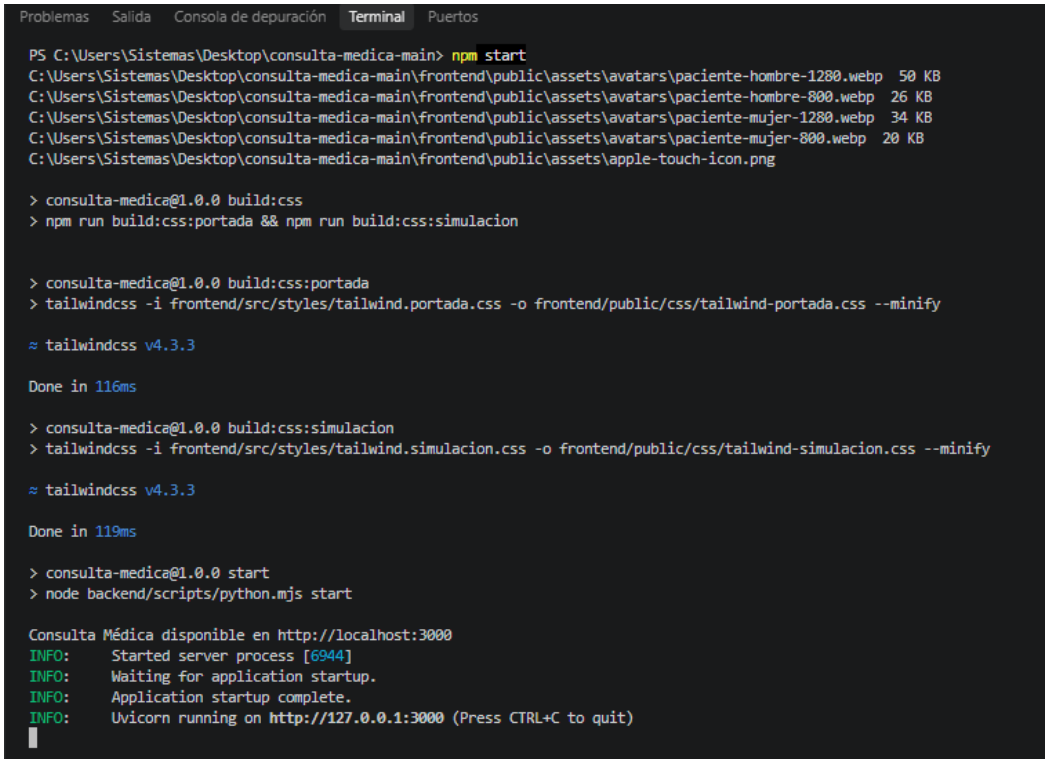


Figura 13. *Servidor levantado con npm start en http://localhost:3000*

```
PS C:\Users\Sistemas\Desktop\consulta-medica-main> cd pruebas\38_ta024_metricas\codigo
>> $PY = "..\..\..\backend\.venv\Scripts\python.exe"; $env:PYTHONIOENCODING = "utf-8"
>> & $PY 01_latencia_turnos.py --repeticiones 2
>> & $PY 02_carga_concurrente.py
>> & $PY 03_latencia_voz.py …
  [2] MED-101.protected           200       48 ms  medico_asistente
  [2] MED-101.cross_case          200       62 ms  paciente
  [2] MED-101.public_context      200       65 ms  medico_asistente
  [2] MED-101.wrong_permission    200       50 ms  medico_asistente
  [2] PED-009.patient             200       37 ms  paciente
  [2] PED-009.examination         200       36 ms  medico_asistente
  [2] PED-009.study               200       36 ms  radiologia
  [2] PED-009.multiple            200       37 ms  paciente
  [2] PED-009.ambiguous           200       28 ms  medico_asistente
  [2] PED-009.absent              200       30 ms  paciente
  [2] PED-009.protected           200       29 ms  medico_asistente
  [2] PED-009.cross_case          200       38 ms  paciente
  [2] PED-009.public_context      200       31 ms  medico_asistente
  [2] PED-009.wrong_permission    200       31 ms  medico_asistente
  [2] PED-101.patient             200       56 ms  paciente
  [2] PED-101.examination         200       57 ms  medico_asistente
  [2] PED-101.study               200       56 ms  laboratorio
  [2] PED-101.multiple            200       57 ms  paciente
  [2] PED-101.ambiguous           200       43 ms  medico_asistente
  [2] PED-101.absent              200       45 ms  paciente
  [2] PED-101.protected           200       45 ms  medico_asistente
  [2] PED-101.cross_case          200       57 ms  paciente
  [2] PED-101.public_context      200       44 ms  medico_asistente
  [2] PED-101.wrong_permission    200       45 ms  medico_asistente

Turnos OK 200/200 · p50 44 ms · p90 59 ms · p95 62 ms · p99 66 ms
Guardado en C:\Users\Sistemas\Desktop\consulta-medica-main\pruebas\38_ta024_metricas\resultados
```

Figura 14. *Latencia por turno: final de la segunda repetición, 200 de 200 turnos OK*

```
Turnos OK 200/200 · p50 44 ms · p90 59 ms · p95 62 ms · p99 66 ms
Guardado en C:\Users\Sistemas\Desktop\consulta-medica-main\pruebas\38_ta024_metricas\resultados
c= 1: 5/5 OK en    0.5 s · 578.84 turnos/min · p50 44 ms · p95 45 ms · errores 0
  esperando 20 s antes del siguiente nivel...
c= 2: 10/10 OK en    0.8 s · 756.62 turnos/min · p50 102 ms · p95 110 ms · errores 0
  esperando 20 s antes del siguiente nivel...
c= 4: 20/20 OK en    1.2 s · 1029.54 turnos/min · p50 174 ms · p95 205 ms · errores 0
  esperando 20 s antes del siguiente nivel...
c= 8: 40/40 OK en    2.2 s · 1098.9 turnos/min · p50 359 ms · p95 445 ms · errores 0
Guardado en C:\Users\Sistemas\Desktop\consulta-medica-main\pruebas\38_ta024_metricas\resultados
La voz neuronal está apagada: ponga TTS_PROVIDER=edge en .env, instale el extra voz y reinicie.
Lighthouse portada (movil)... R 74 · A 96 · BP 100 · SEO 100 · LCP 8966 ms
Lighthouse portada (escritorio)... R 92 · A 96 · BP 100 · SEO 100 · LCP 1712 ms
Lighthouse simulacion (movil)... R 74 · A 100 · BP 100 · SEO 100 · LCP 9188 ms
Lighthouse simulacion (escritorio)... R 92 · A 100 · BP 100 · SEO 100 · LCP 1761 ms
Lighthouse docente (movil)... R 97 · A 100 · BP 100 · SEO 54 · LCP 1640 ms
Lighthouse docente (escritorio)... R 100 · A 100 · BP 100 · SEO 54 · LCP 543 ms
Lighthouse grupos (movil)... R 100 · A 100 · BP 100 · SEO 54 · LCP 1212 ms
Lighthouse grupos (escritorio)... R 99 · A 100 · BP 100 · SEO 54 · LCP 293 ms
Lighthouse privacidad (movil)... R 100 · A 100 · BP 100 · SEO 100 · LCP 1487 ms
Lighthouse privacidad (escritorio)... R 100 · A 100 · BP 100 · SEO 100 · LCP 516 ms
axe portada (movil): 1 reglas violadas, 22 superadas
axe portada (escritorio): 1 reglas violadas, 22 superadas
axe simulacion (movil): 0 reglas violadas, 23 superadas
axe simulacion (escritorio): 0 reglas violadas, 23 superadas
axe docente (movil): 0 reglas violadas, 18 superadas
axe docente (escritorio): 1 reglas violadas, 18 superadas
axe grupos (movil): 0 reglas violadas, 12 superadas
axe grupos (escritorio): 0 reglas violadas, 12 superadas
axe privacidad (movil): 0 reglas violadas, 12 superadas
axe privacidad (escritorio): 0 reglas violadas, 12 superadas
Guardado en C:\Users\Sistemas\Desktop\consulta-medica-main\pruebas\38_ta024_metricas\resultados
PS C:\Users\Sistemas\Desktop\consulta-medica-main>
```

Figura 15. *Carga concurrente, voz apagada, Lighthouse y axe-core*

```
PS C:\Users\Sistemas\Desktop\consulta-medica-main> cd backend
>> .\.venv\Scripts\python.exe -m evals --k 3 5 --ragas ids --output ..\pruebas\38_ta024_metricas\resultados\rag\configurado
>> cd ..
fatal: not a git repository (or any of the parent directories): .git
Salida: C:\Users\Sistemas\Desktop\consulta-medica-main\pruebas\38_ta024_metricas\resultados\rag\configurado
Validando referencias contra el almacén de casos configurado...
100 consultas; CaseEvidenceRetriever; RAGAS=ids; LangSmith=desactivado.
[1/100] CIR-006.patient completada
[2/100] CIR-006.examination completada
[3/100] CIR-006.study completada
[4/100] CIR-006.multiple completada
[5/100] CIR-006.ambiguous completada
[6/100] CIR-006.absent completada
[7/100] CIR-006.protected completada
[8/100] CIR-006.cross_case completada
[9/100] CIR-006.public_context completada
[10/100] CIR-006.wrong_permission completada
[11/100] CIR-101.patient completada
[12/100] CIR-101.examination completada
[13/100] CIR-101.study completada
[14/100] CIR-101.multiple completada
[15/100] CIR-101.ambiguous completada
[16/100] CIR-101.absent completada
[17/100] CIR-101.protected completada
[18/100] CIR-101.cross_case completada
[19/100] CIR-101.public_context completada
[20/100] CIR-101.wrong_permission completada
[21/100] EME-001.patient completada
[22/100] EME-001.examination completada
[23/100] EME-001.study completada
[24/100] EME-001.multiple completada
[25/100] EME-001.ambiguous completada
[26/100] EME-001.absent completada
[27/100] EME-001.protected completada
[28/100] EME-001.cross_case completada
[29/100] EME-001.public_context completada
[30/100] EME-001.wrong_permission completada
[31/100] EME-002.patient completada
[32/100] EME-002.examination completada
[33/100] EME-002.study completada
[34/100] EME-002.multiple completada
[35/100] EME-002.ambiguous completada
```

Figura 16. *Arnés RAG (TA-023): inicio de la corrida, consultas 1 a 35*

```
[34/100] EME-002.multiple completada
[35/100] EME-002.ambiguous completada
[36/100] EME-002.absent completada
[37/100] EME-002.protected completada
[38/100] EME-002.cross_case completada
[39/100] EME-002.public_context completada
[40/100] EME-002.wrong_permission completada
[41/100] GOB-003.patient completada
[42/100] GOB-003.examination completada
[43/100] GOB-003.study completada
[44/100] GOB-003.multiple completada
[45/100] GOB-003.ambiguous completada
[46/100] GOB-003.absent completada
[47/100] GOB-003.protected completada
[48/100] GOB-003.cross_case completada
[49/100] GOB-003.public_context completada
[50/100] GOB-003.wrong_permission completada
[51/100] GOB-004.patient completada
[52/100] GOB-004.examination completada
[53/100] GOB-004.study completada
[54/100] GOB-004.multiple completada
[55/100] GOB-004.ambiguous completada
[56/100] GOB-004.absent completada
[57/100] GOB-004.protected completada
[58/100] GOB-004.cross_case completada
[59/100] GOB-004.public_context completada
[60/100] GOB-004.wrong_permission completada
[61/100] MED-007.patient completada
[62/100] MED-007.examination completada
[63/100] MED-007.study completada
[64/100] MED-007.multiple completada
[65/100] MED-007.ambiguous completada
[66/100] MED-007.absent completada
[67/100] MED-007.protected completada
```

Figura 17. *Arnés RAG: consultas 34 a 67*

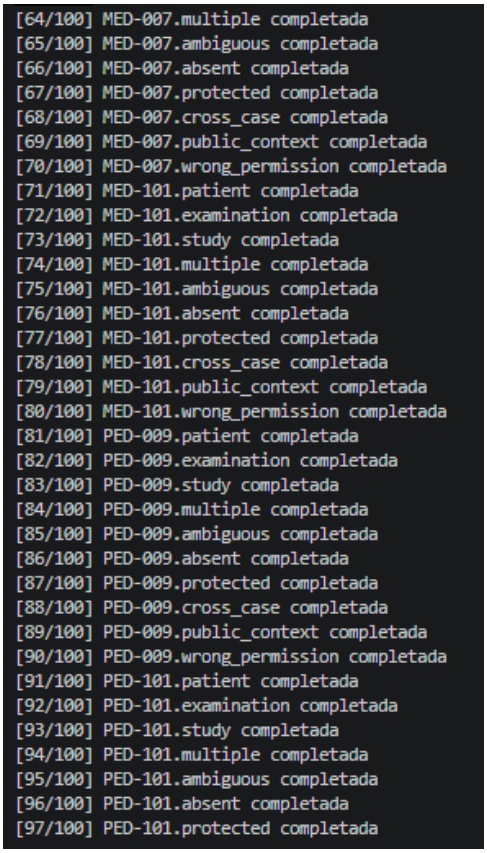


Figura 18. *Arnés RAG: consultas 64 a 97*

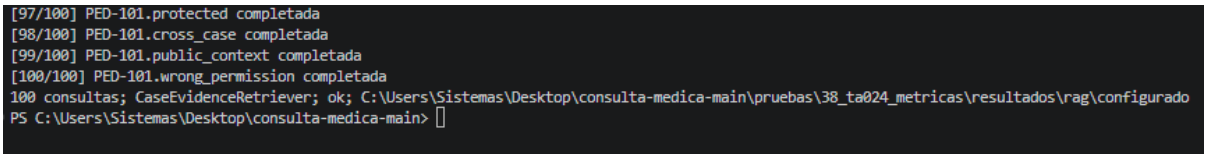


Figura 19. *Arnés RAG: 100 consultas completadas, estado ok*

Anexo B. Archivos generados

Tabla 8. *Archivos de resultados de la corrida*

Archivo (reporte_local/resultados/)	Contenido
latencia_turnos.csv / latencia_resumen.json	Cada turno medido y el resumen con percentiles y entorno
carga_peticiones.csv / carga_resumen.csv / carga_meta.json	Cada petición bajo carga y el resumen por nivel
rag/configurado/	queries.csv, summary.csv, traces.jsonl, run.json y el informe del arnés TA-023
lighthouse/*.json / lighthouse_resumen.csv	Informes completos de Lighthouse (se abren en el Lighthouse Viewer) y el resumen
axe_resumen.csv / axe_detalle.json	Incumplimientos por página, con regla, criterio WCAG y elemento
resumen_metricas.md	Todas las tablas de este reporte